

Ejercicio 2.1: Ejemplo outliers con Regresión

Silvia Pineda

Lectura de datos

```
cars_original <- cars # original data
### Introducimos unos outliers de forma manual
outliers <- data.frame(speed=c(19,19,20,20,20), dist=c(190, 186, 210, 220, 218))
cars_outliers <- rbind(cars_original, outliers) # data with outliers.
```

Ajustar recta de regresión con datos originales

```
summary(lm(cars_original$dist~cars_original$speed))
```

Call:

```
lm(formula = cars_original$dist ~ cars_original$speed)
```

Residuals:

Min	1Q	Median	3Q	Max
-29.069	-9.525	-2.272	9.215	43.201

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-17.5791	6.7584	-2.601	0.0123 *
cars_original\$speed	3.9324	0.4155	9.464	1.49e-12 ***


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.38 on 48 degrees of freedom

```
Multiple R-squared:  0.6511,    Adjusted R-squared:  0.6438
F-statistic: 89.57 on 1 and 48 DF,  p-value: 1.49e-12
```

```
library(ggplot2)
ggp_original <- ggplot(cars_original,aes(speed, dist)) +
geom_point()

plot1<-ggp_original +
stat_smooth(method = "lm",
formula = y ~ x,
geom = "smooth")
plot1
```



En esta regresión lineal, vemos un buen ajuste con un $R^2 = 0.65$ y un p-valor de la variable $speed = 1.49 * 10^{-12}$. Además en la recta de regresión vemos también un buen ajuste a cada uno de los puntos.

Ajustar recta de regresión con datos con outliers

```
summary(lm(cars_outliers$dist~cars_outliers$speed))
```

Call:

```
lm(formula = cars_outliers$dist ~ cars_outliers$speed)
```

Residuals:

Min	1Q	Median	3Q	Max
-50.425	-26.583	-11.516	4.962	137.575

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)		
(Intercept)	-34.847	19.174	-1.817	0.0748 .		
cars_outliers\$speed	5.864	1.155	5.075	5.09e-06 ***		


Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'	0.1 ' '	1

Residual standard error: 44.01 on 53 degrees of freedom

Multiple R-squared: 0.3271, Adjusted R-squared: 0.3144

F-statistic: 25.76 on 1 and 53 DF, p-value: 5.089e-06

```
ggp_outlier <- ggplot(cars_outliers,aes(speed, dist)) +  
  geom_point()  
  
plot2<-ggp_outlier + stat_smooth(method = "lm",  
                                    formula = y ~ x,geom = "smooth")  
  
plot2
```



En este caso, vemos claramente los outliers fuera de la recta de regresión y vemos como tanto el R^2 como el nivel de significación han disminuido.

Diagramas de cajas para la detección de outliers


```
p1 <- ggplot(cars_original, aes(y = dist)) +
  geom_boxplot(fill = "skyblue", outlier.color = "red", outlier.shape = 16) +
  scale_y_continuous(limits = c(0, 210))

p2 <- ggplot(cars_outliers, aes(y = dist)) +
  geom_boxplot(fill = "salmon", outlier.color = "red", outlier.shape = 16) +
  scale_y_continuous(limits = c(0, 210))

library(patchwork)
combined_plot <- p1 + p2 + plot_layout(ncol = 2)

# Mostrar el gráfico combinado
print(combined_plot)
```

Warning: Removed 2 rows containing non-finite outside the scale range
(`stat_boxplot()`).



Aquí vemos como en la segunda bases de datos, los outliers se ven claramente muy alejados de los bigotes.