Ejercicio 3.1: Detección de datos perdidos

Silvia Pineda

Carga de Datos y Librerías

```r
library(naniar)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ------------------------ tidyverse 2.0.0 --
v dplyr     1.1.4     v readr     2.1.5
v forcats   1.0.1     v stringr   1.6.0
v ggplot2   4.0.0     v tibble    3.3.0
v lubridate 1.9.4     v tidyr     1.3.1
v purrr     1.2.0
-- Conflicts ------------------------------------------ tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to becom
```

```r
data <- read.csv("students_FP.csv",
  na.strings = c("", "NA", "NaN", "NULL"),
  stringsAsFactors = TRUE
)
```

1.Cuantifica el número de datos perdidos

```r
summary(data)
```

```
  student_id  hours_study_week attendance_pct        gpa
 SID1000:  1   Min.   : 0.000   Min.   : 65.00   Min.   : 0.350
 SID1001:  1   1st Qu.: 6.700   1st Qu.: 81.50   1st Qu.: 5.235
 SID1002:  1   Median : 9.400   Median : 86.30   Median : 6.220
 SID1003:  1   Mean   : 9.682   Mean   : 86.45   Mean   : 6.112
 SID1004:  1   3rd Qu.:13.200   3rd Qu.: 92.60   3rd Qu.: 7.115
 SID1005:  1   Max.   :22.400   Max.   :100.00   Max.   :10.000
 (Other):294   NA's   :23       NA's   :15       NA's   :61
  exam_score                        program         shift
 Min.   :  7.30   IT Support            :53   Afternoon:119
 1st Qu.: 43.45   Network Administration:72   Evening  : 73
 Median : 58.90   Software Engineering  :78   Morning  :108
 Mean   : 58.04   Web Development       :90
 3rd Qu.: 71.92   NA's                  : 7
 Max.   :100.00
```

```r
# Porcentaje total de datos faltantes
pct_miss(data)
```

```
[1] 5.047619
```

```r
# Número de datos faltantes en todo el dataset
n_miss(data)
```

```
[1] 106
```

```r
# Porcentaje de filas completas si borramos todas las filas que contienen al menos un dato fa
pct_complete_case(data)
```

```
[1] 71.33333
```

```r
# Número de filas completas si borramos todas las filas que contienen al menos un dato faltan
n_case_complete(data)
```

```
[1] 214
```

El % total de datos faltantes es de 5.2% que hacen un total de 109 celdas faltantes, pero si lo contabilizamos en filas completas, sólo nos quedarían 211 observaciones que hacen el 70% del total de la base de datos que son 300 observaciones, por tanto, debemos hacer un tratamiento de datos faltantes para poder analizar la base de datos actual.

2.Visualiza los datos perdidos de forma global

```
gg_miss_var(data, show_pct = TRUE)
```

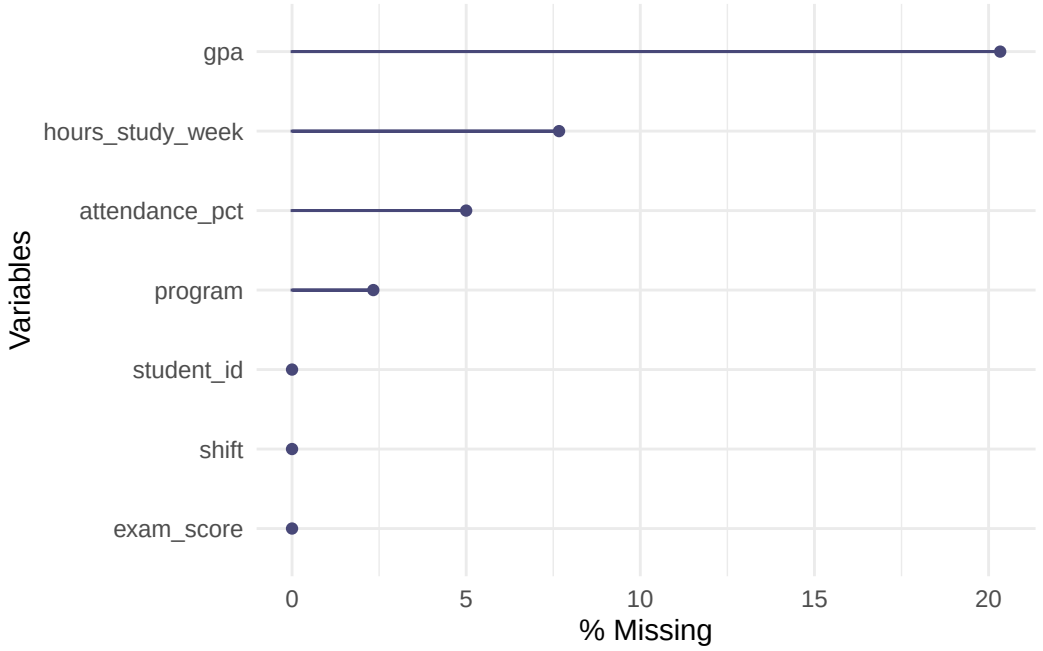

Tenemos 4 variables de un total de 7 con datos faltantes, de las cuales `gpa` es la que mayor % tiene con alrededor de un 20%, luego `hours_study_week` tiene casi un 10%, `attendance_pct` y `program` con un 5% y 2% aproximadamente.

```
vis_miss(data,cluster = TRUE)  +
  theme(axis.text.x = element_text(angle = 90))
```

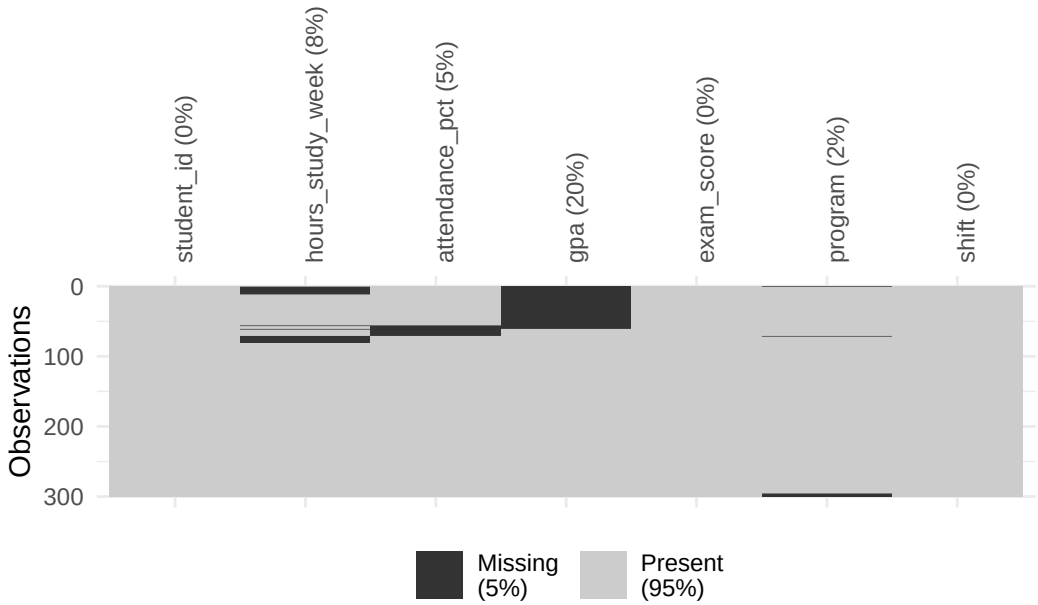

En este gráfico vemos que hay algunas observaciones que podrían compartir un patrón similar de datos faltantes, pero no parece que hay muchas observaciones compartiendo datos missing.

3.Clasifica en MAR, MNAR y MCAR los datos perdidos.

Primero visualizamos por subgrupos de las variables cualitativas

```
gg_miss_var(data, show_pct = TRUE,facet = program)
```

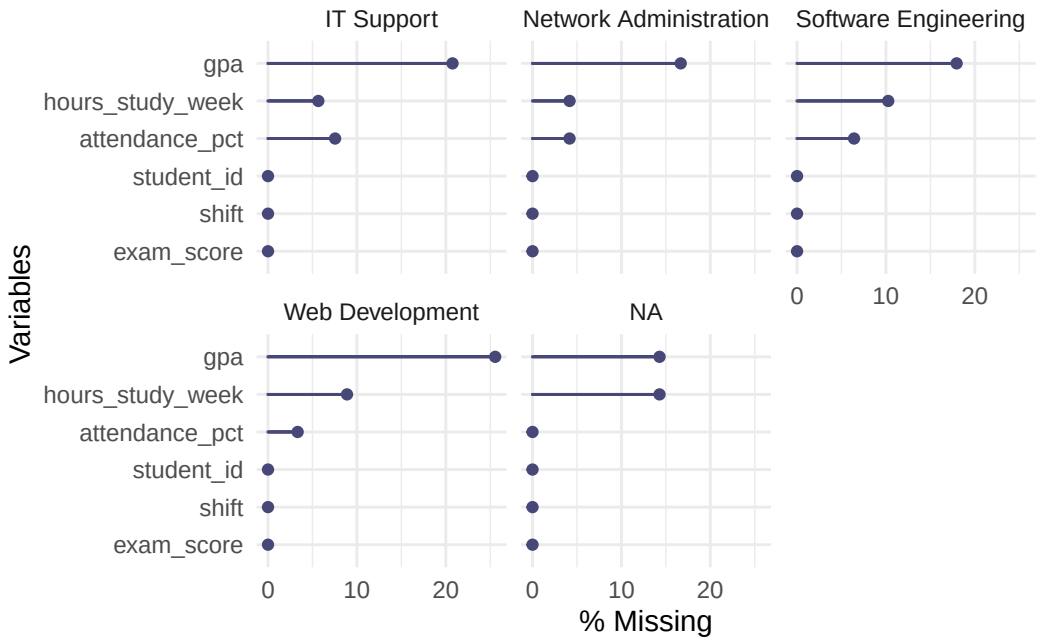


```r
gg_miss_var(data, show_pct = TRUE,facet = shift)
```

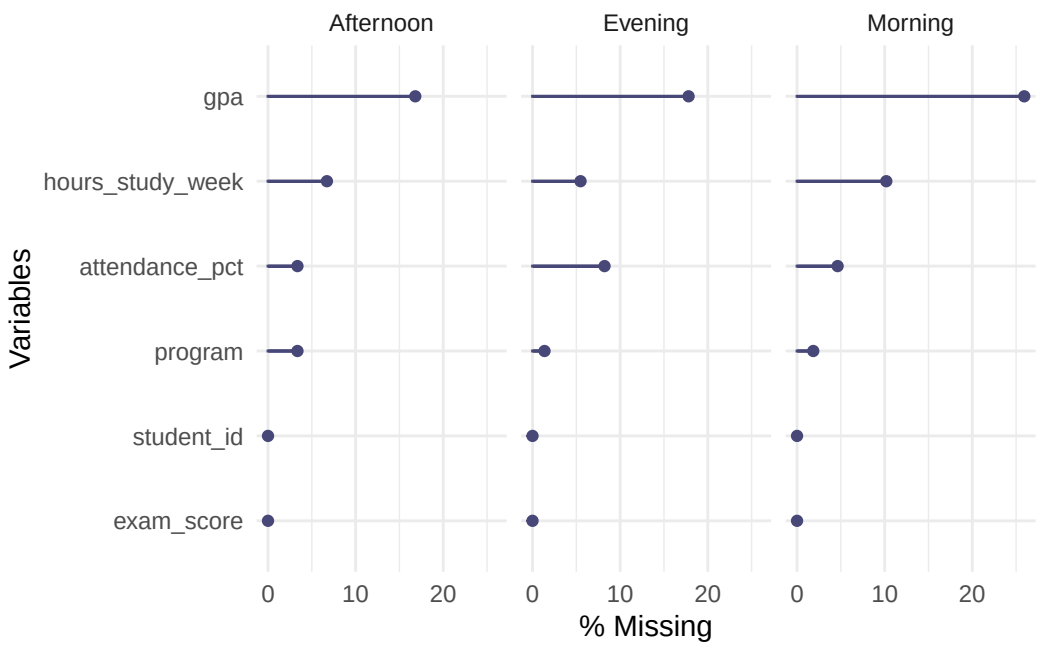

- No parece que haya una relación directa con ninguna de las variables cualitativas

Segundo visualizamos por las variables cuantitativas

```
###hours_study_week
ggplot(data = data, aes (x = hours_study_week ,
                         y =attendance_pct )) + geom_miss_point()
```

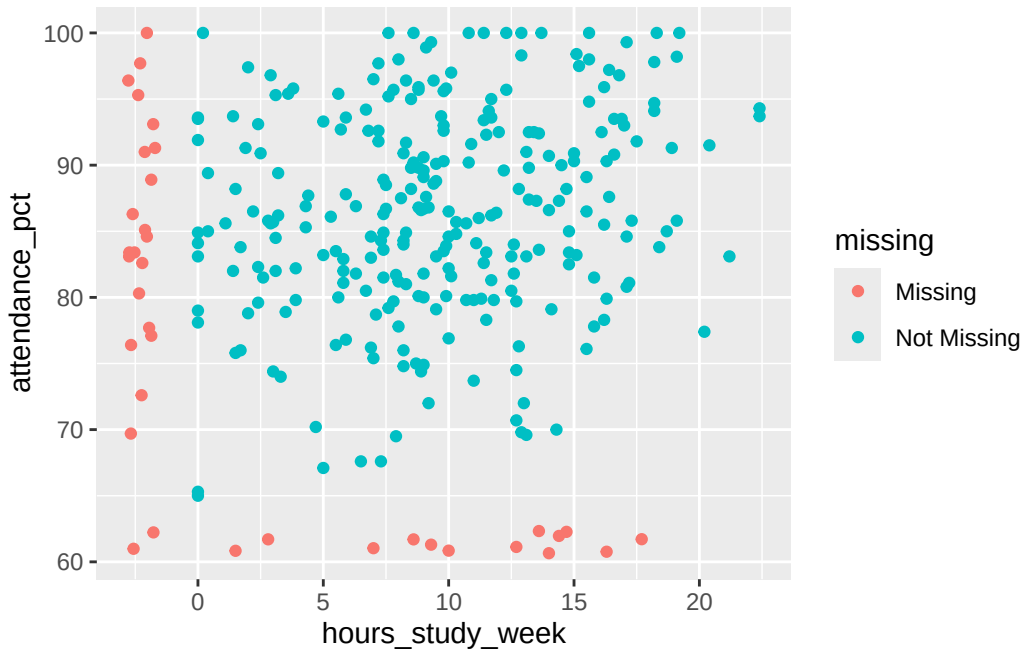


```
ggplot(data = data, aes (x = hours_study_week ,
                         y =gpa )) + geom_miss_point()
```

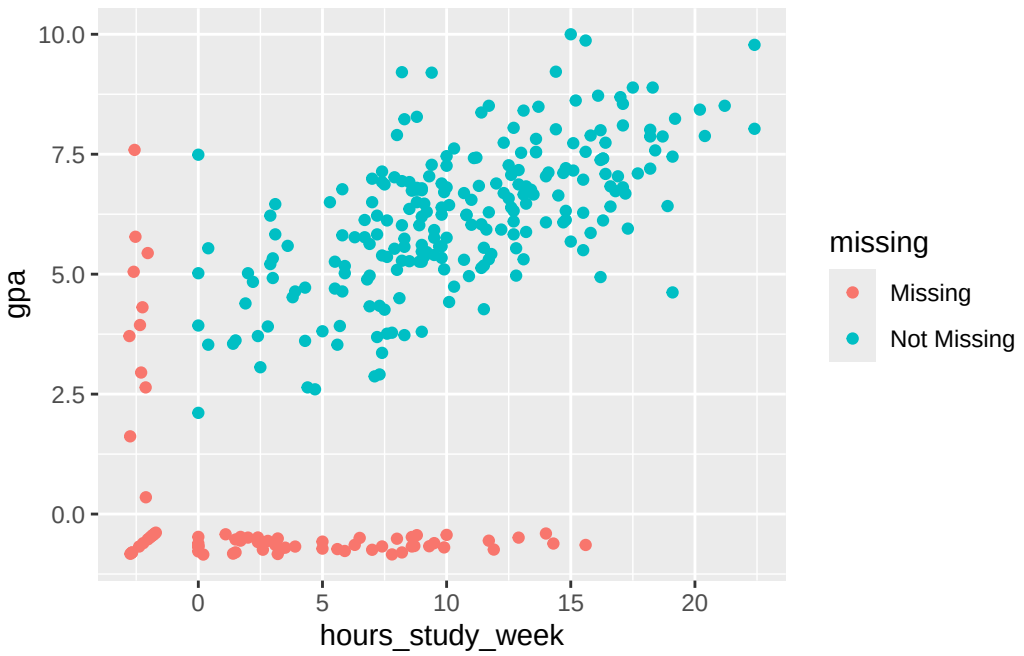


```
ggplot(data = data, aes (x = hours_study_week ,
                         y =exam_score )) + geom_miss_point()
```

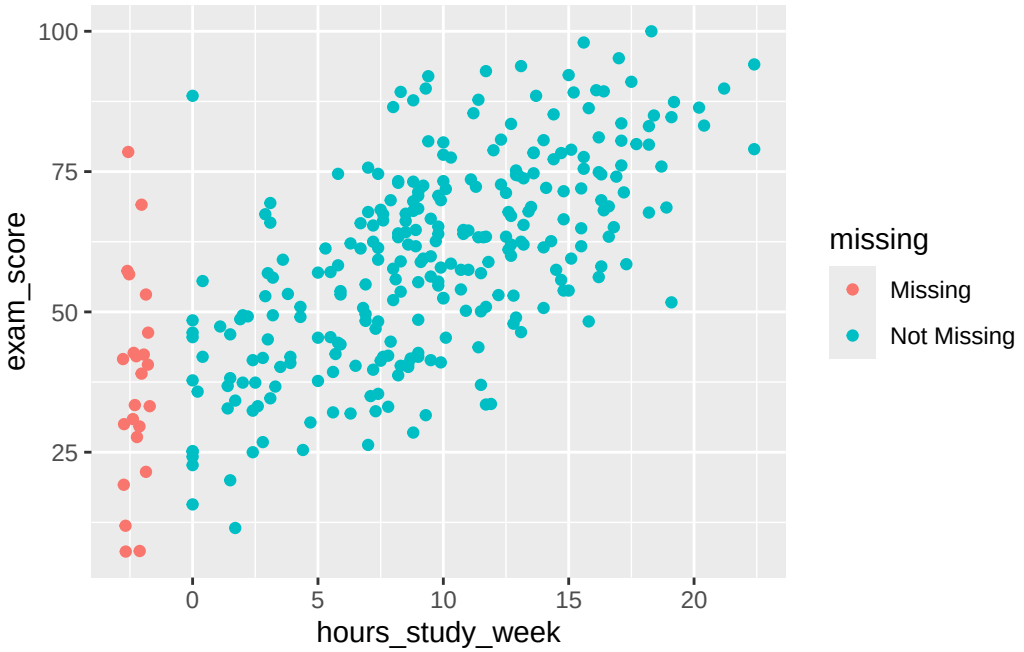

- Los `NA` de `hours_study_week` corresponden a valores bajos de `exam_score` y valores bajos de `gpa`, por tanto esta asociación corresponde a variables observadas (rendimiento)

y podría corresponder a un **MAR.**

- Pero cuidado porque no es exclusivo, hay valores que no son NA que corresponden también a la asociación por lo que podría estar relacionado con datos no observados y por tanto ser **MNAR**.
- Imagina que no reportaron las horas de estudio aquellas personas que estudiaron cero horas y no quiesieron reportarlo, esto sería MNAR porque falta por algo no observado.
- Si imputamos con el supuesto MAR y la relación entre ambas variables, si es un MAR será correcto, si es un MNAR será falso.

```
##Attendance_pct
ggplot(data = data, aes (x = attendance_pct ,
                         y =exam_score )) + geom_miss_point()
```

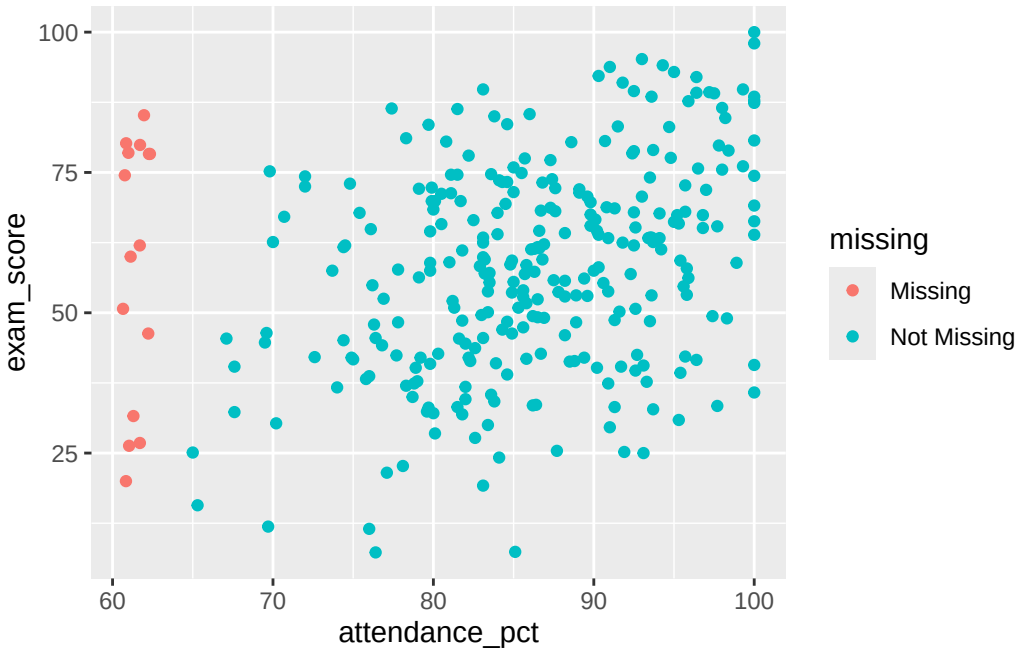


```
ggplot(data = data, aes (x = attendance_pct ,
                         y =gpa )) + geom_miss_point()
```

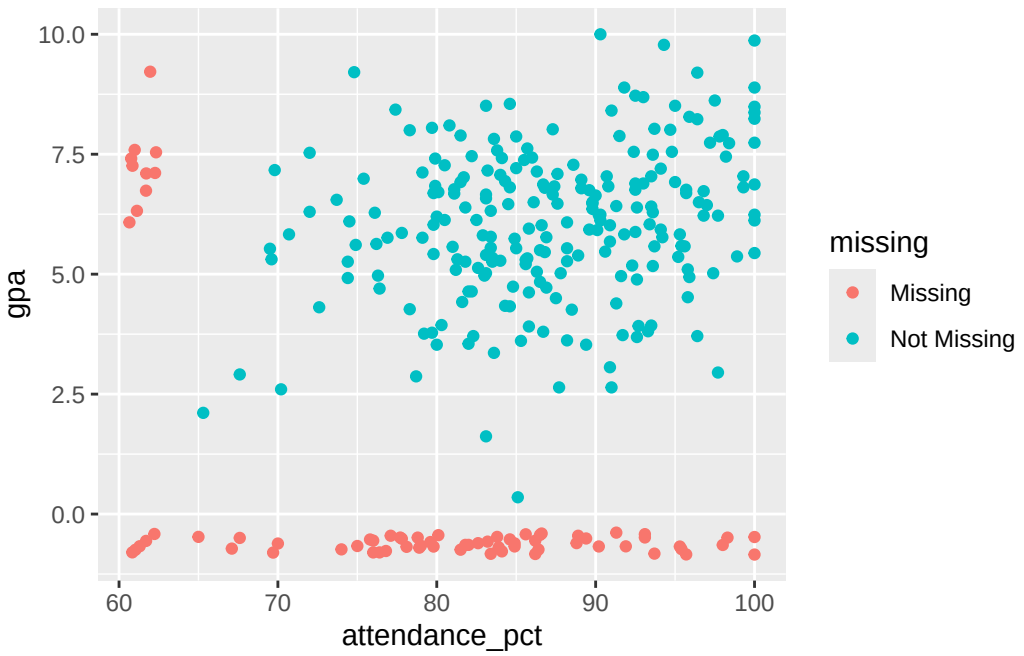


```
ggplot(data = data, aes (x = attendance_pct ,
                         y =hours_study_week )) + geom_miss_point()
```

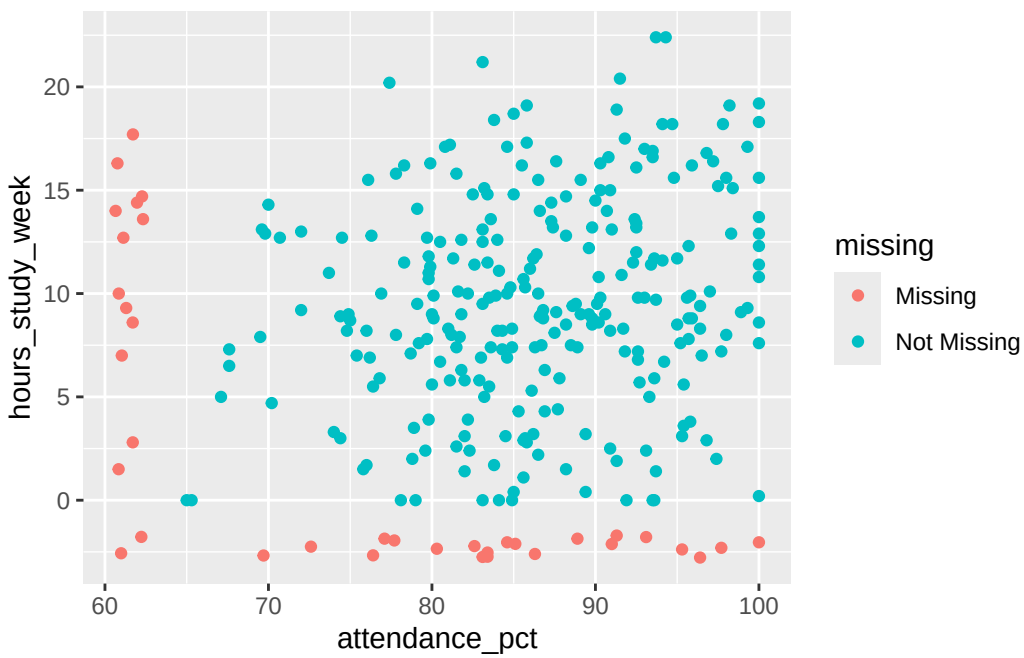

- Los `NA` de `attendance_pct` corresponden a valores al rededor del 7.5 de `gpa`, pero la asociación es un poco rara y no sabemos cuál podría ser la razón, por ejemplo exención

de asistencia por programa de honores, prácticas externas), por tanto sería indicativo de un **MNAR**.

- Aquí la diferencia es que estas variables no parecen estar relacionadas entre si y la imputación podría no ser buena para ninguno de los dos.

```
ggplot(data = data, aes (x = gpa ,
                         y = exam_score )) + geom_miss_point()
```

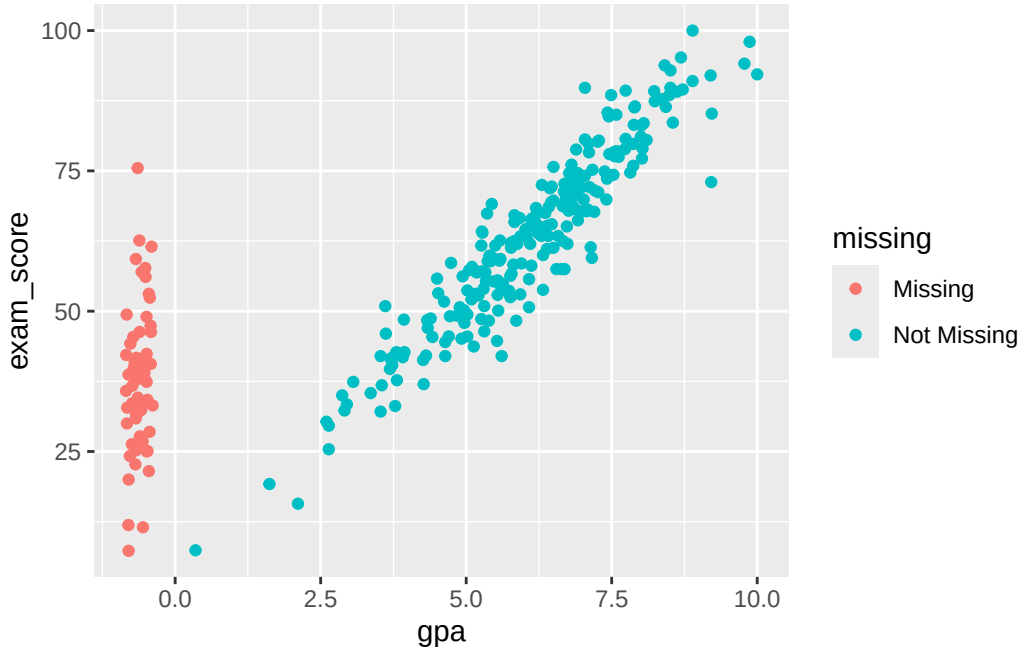


```
ggplot(data = data, aes (x = gpa ,
                         y = attendance_pct )) + geom_miss_point()
```

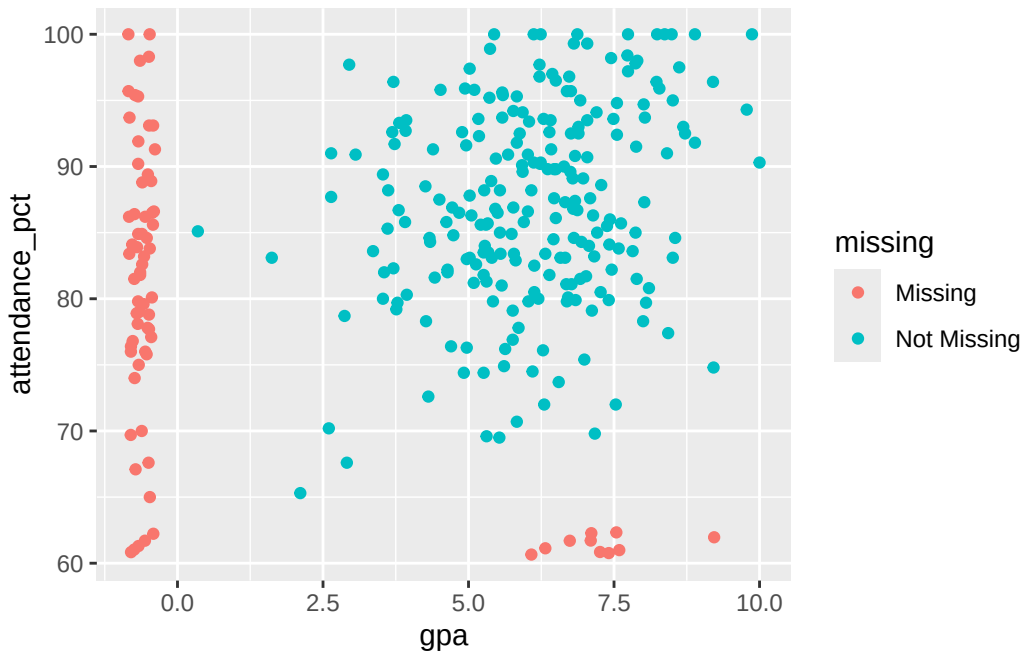


```
ggplot(data = data, aes (x = gpa ,
                         y = hours_study_week )) + geom_miss_point()
```

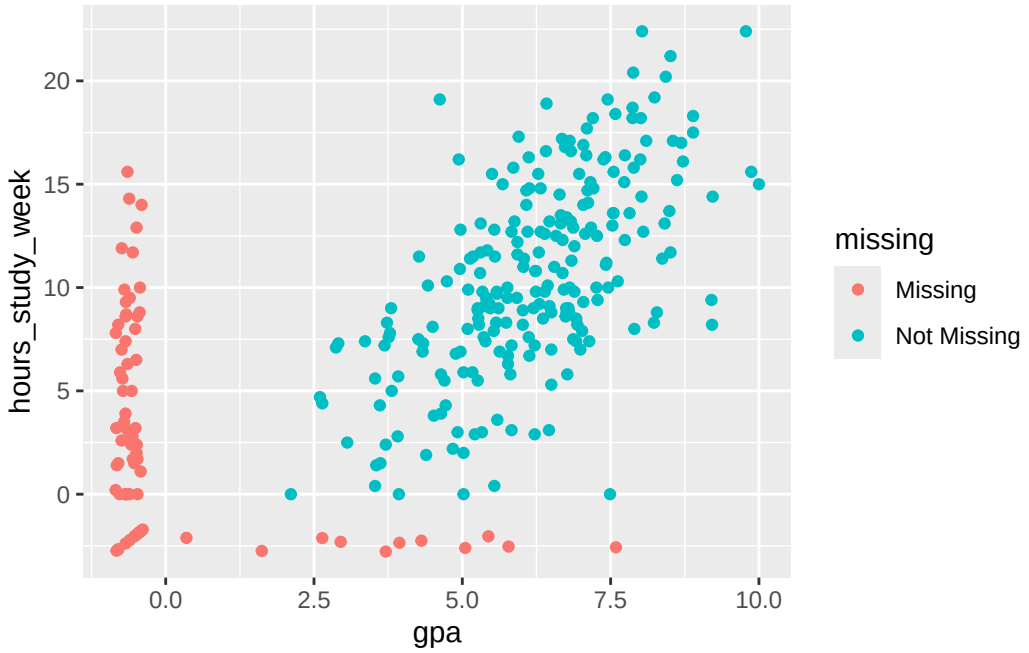

- Los `NA` de `gpa` corresponden mayoritariamente a valores con datos inferiores de `hours_study_week` y con datos menores de `exam_score`. Además estas variables están

muy relacionadas entre si. Podría ser un MAR.

- Imagina que no tienen gpa los que no aprobaron alguno de los parciales que no viene reportado en la base de datos, entonces podría ser un MNAR.
- Como hay una asociación fuerte podremos usar un modelo para imputar.

Tercero, con las variables shadow podemos verificar

1) `hours_study_week` relacionado con `gpa` y `exam_score`

```
##hours_study_week re
shadowed_data <- data %>%
bind_shadow()

ggplot (data = shadowed_data,
        mapping = aes(x = gpa,
                      colour = hours_study_week_NA)) + geom_density()
```

```
Warning: Removed 61 rows containing non-finite outside the scale range
(`stat_density()`).
```

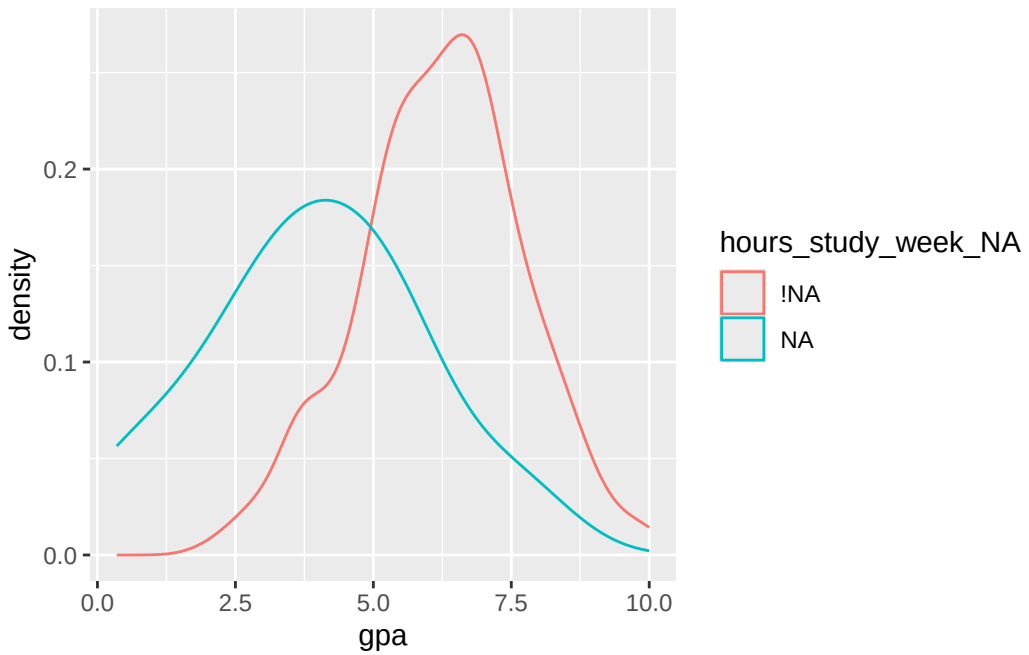

```r
ggplot (data = shadowed_data,
        mapping = aes(x = exam_score,
                      colour = hours_study_week_NA)) + geom_density()
```

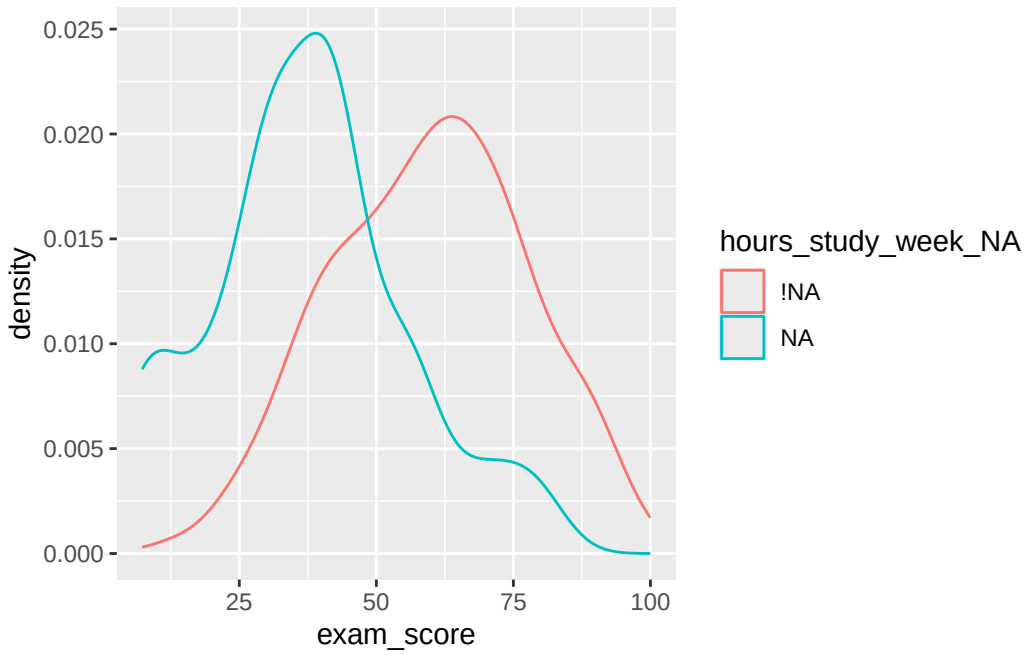

Se ve la asociación de los NA de hours_study_week con gpa y exam_score

2) `gpa` con `hours_study_week` y `exam_score`

```r
#GPA
ggplot (data = shadowed_data,
        mapping = aes(x = hours_study_week,
                      colour = gpa_NA)) + geom_density()
```

```
Warning: Removed 23 rows containing non-finite outside the scale range
(`stat_density()`).
```

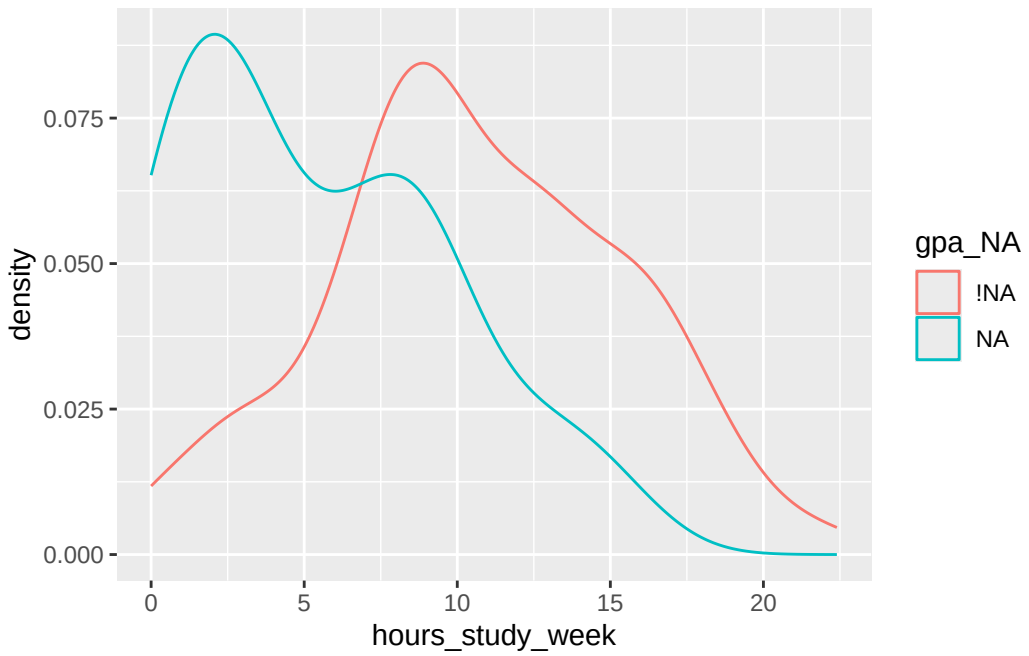


```
ggplot (data = shadowed_data,
        mapping = aes(x = exam_score,
                      colour = gpa_NA)) + geom_density()
```

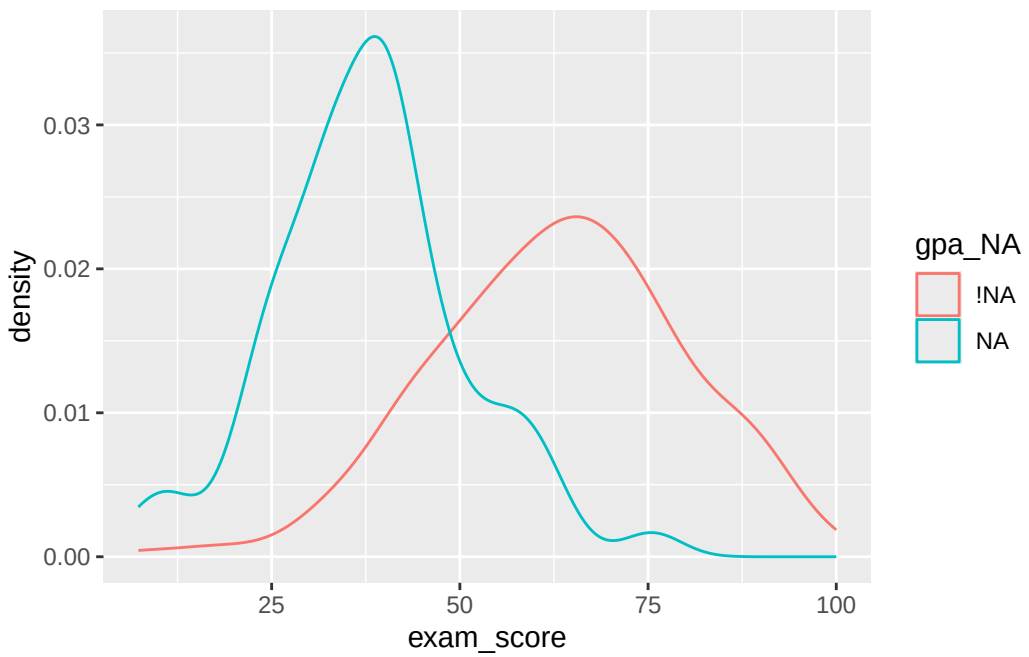

3) `attendance_pct` con `gpa` y `exam_score`

```r
ggplot (data = shadowed_data,
        mapping = aes(x = gpa,
                      colour = attendance_pct_NA)) + geom_density()
```

```
Warning: Removed 61 rows containing non-finite outside the scale range
(`stat_density()`).
```

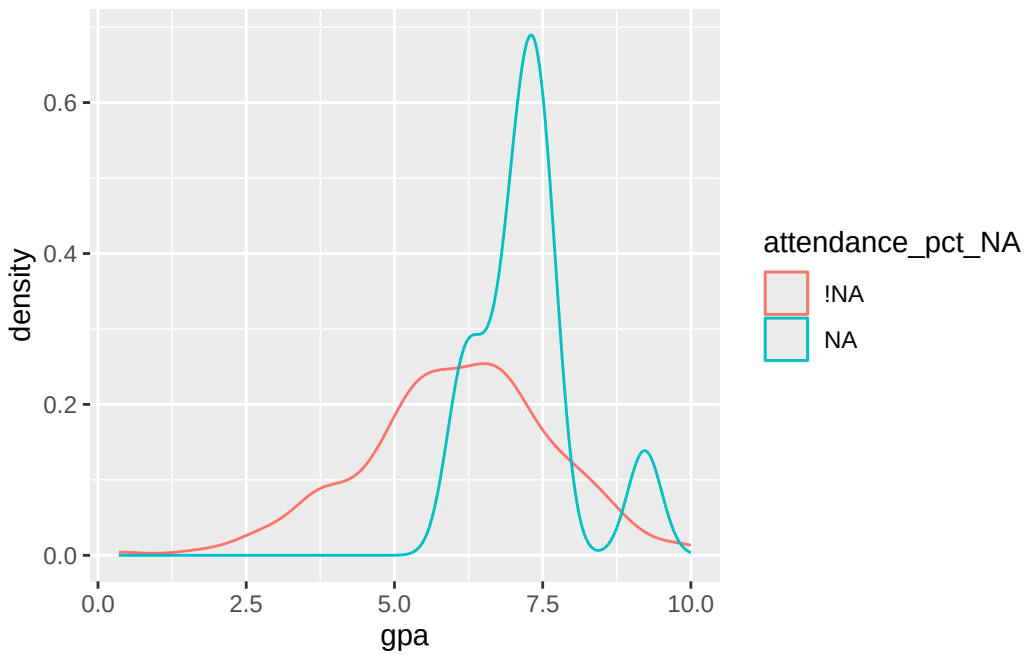


```r
ggplot (data = shadowed_data,
        mapping = aes(x = exam_score,
                      colour = attendance_pct_NA)) + geom_density()
```

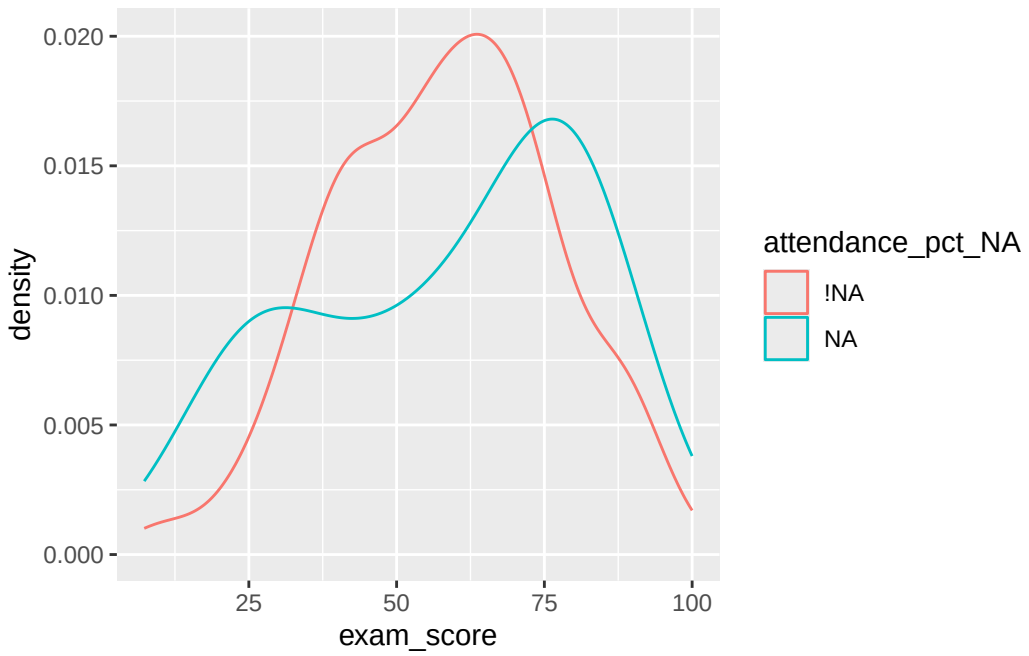


```
ggplot(shadowed_data, aes(x = shift, fill = attendance_pct_NA)) +
  geom_bar(position = "fill")
```

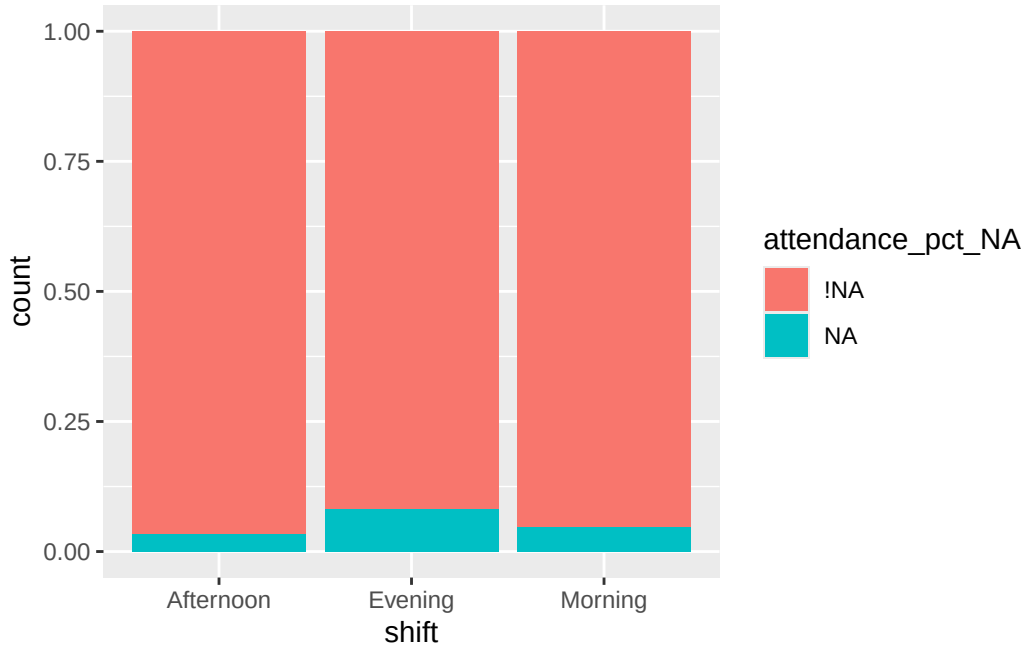

Se ve un leve desplazamiento en este caso, pero estas dos variables no están relacionadas y por tanto podrían ser MNAR.

Conclusión

Los `NA` de `gpa` asumiremos que son **MAR** relacionados con hours_study_week/exam_score.

Los `NA` de `hours_study_week` asumiremos que son **MAR** relacionados con gpa/exam_score.

Los `NA` de `attendance_pct` asumiremos que son **MNAR** ya que se observan dependencias, pero no explicadas por lo observado.

Los `NA` de `program` asumiremos que son **MCAR** porque son muy pocos y no hemos visto nada relavante.